

Zajęcia laboratoryjne 10. – regresja logistyczna

Generowanie zbioru danych do regresji logistycznej

Rozmiar próby: $n = 300$, liczba zmiennych objaśniających $X_1, \dots, X_p$: $p = 20$, przy czym zmienna X_1 jest tożsamościowo równa 1.

1. Przyjąć, że jedynie zmienne $X_1, \dots, X_{10}$ wpływają na Y , przypisując im (wybrane) niezerowe współczynniki $\beta_1, \dots, \beta_{10}$. Pozostałym zmiennym przypisać współczynniki regresji równe zeru, tzn. $\beta_{11} = \dots = \beta_{20} = 0$.
2. Dla $i = 1, 2, \dots, n$ wykonać następujące kroki:
 - (a) Przyjąć $x_{i1} = 1$ oraz wygenerować wartości $x_{i2}, x_{i3}, \dots, x_{ip}$ pozostałych $p - 1$ zmiennych objaśniających $X_2, \dots, X_p$. Przyjąć, że każda z tych wartości pochodzi z rozkładu normalnego (np. `rnorm()`).
 - (b) Wygenerować wartość y_i binarnej zmiennej objaśnianej Y , która przyjmuje wartości 0 i 1 z prawdopodobieństwami odpowiednio $1 - \pi(\mathbf{x}_i)$ oraz $\pi(\mathbf{x}_i)$, gdzie $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})$ oraz

$$\pi(\mathbf{x}_i) := P(Y = 1 \mid X_1 = x_{i1}, \dots, X_p = x_{ip}) = \frac{1}{1 + e^{-(\beta_1 x_{i1} + \dots + \beta_p x_{ip})}}.$$

3. Połączyć wszystkie dane w jedną ramkę danych (`data.frame`), zawierającą kolumny: $y, x_1, \dots, x_p$, a następnie zapisać otrzymany zbiór danych do pliku.

Konstrukcja modelu regresji logistycznej

1. Wczytać do pakietu statystycznego dane z utworzonego pliku.
 - (a) Podzielić losowo zbiór danych w proporcji 70 : 30 na zbiór **trenin-gowy** i zbiór **testowy**, dbając o to, aby frakcja (odsetek) rekordów ze zmienną $y = 1$ w obu zbiorach była zbliżona.
 - (b) Wykorzystując **zbiór treningowy**, skonstruować model regresji logistycznej opisujący zależność między zmienną objaśnianą Y a wszystkimi zmiennymi objaśniającymi $X_1, \dots, X_p$.
 - (c) Za pomocą testu ilorazu wiarygodności zweryfikować hipotezę zerową

$$H_0 : \beta_2 = \dots = \beta_p = 0,$$

która stwierdza, że żadna ze zmiennych objaśniających $X_2, \dots, X_p$ nie wpływa na zmienną objaśnianą Y . Wyznaczyć p-wartość testu oraz rozstrzygnąć, czy na poziomie istotności $\alpha = 0.05$ należy odrzucić H_0 .

- (d) Dla każdego z parametrów β_i , $i = 2, \dots, p$:
 - i. wyznaczyć estymatory $\hat{\beta}_i$ oraz ich błędy standardowe SE_{β_i} ,
 - ii. skonstruować przedziały ufności na poziomie $1 - \alpha$,
 - iii. zweryfikować hipotezę $H_0 : \beta_i = 0$ przeciwko $H_1 : \beta_i \neq 0$ na poziomie istotności α .

- (e) Porównać wektor parametrów $\beta = (\beta_1, \dots, \beta_p)$ z jego estymatorem $\hat{\beta} = (\hat{\beta}_1, \dots, \hat{\beta}_p)$. W tym celu sprawdzić, czy estymator $\hat{\beta}$ poprawnie zidentyfikował wszystkie niezerowe elementy wektora β oraz czy prawidłowo określił ich znaki.
2. Zinterpretować dwa niezerowe współczynniki estymatora $\hat{\beta}$ w kategoriach ilorazu szans (odds ratio).
 3. Dla dwóch poziomów odcięcia $\pi_0 = 0.5$ oraz $\pi_0 = 0.7$ wykorzystać **zbiór testowy** do skonstruowania *classification table*. Wyznaczyć miary zdolności predykcyjnej modelu: *sensitivity*, *specificity*, *false positive rate*, *false negative rate*, *overall proportion of correct classifications*.
 4. Wykorzystać zbiór testowy do narysowania krzywej ROC. Wyznaczyć pole pod krzywą ROC (AUC) i zinterpretować jego wartość w kontekście wartości predykcyjnej modelu.