

Zadanie laboratoryjne 11. – regresja logistyczna

1. Wczytać do pakietu statystycznego zbiór testowy wygenerowany podczas poprzednich zajęć.
2. Skonstruować model regresji logistycznej przewidujący wartość zmiennej Y na podstawie dostępnych predyktorów, stosując selekcję postępującą (ang. forward selection). Jako kryterium wyboru zmiennych wykorzystać AIC (Akaike Information Criterion).
3. Porównać wektor parametrów $\beta = (\beta_1, \dots, \beta_p)$ z jego estymatorem $\hat{\beta} = (\hat{\beta}_1, \dots, \hat{\beta}_p)$. W tym celu sprawdzić, czy estymator $\hat{\beta}$ poprawnie zidentyfikował wszystkie niezerowe elementy wektora β oraz czy prawidłowo określił ich znaki.
4. Jeśli otrzymany w ten sposób model zawiera inne predyktory niż poprzedni model, opisać różnice między nimi.
5. **Zadanie teoretyczne.** Przeprowadzając odpowiednie obliczenia uzasadnić poniższe wzory.

- Dla $1 \leq j \leq p$

$$\frac{\partial L(\beta)}{\partial \beta_j} = \sum_i y_i x_{ij} - \sum_i n_i x_{ij} \frac{\exp(\sum_k \beta_k x_{ik})}{1 + \exp(\sum_k \beta_k x_{ik})}$$

- Dla $1 \leq a \leq p$ i $1 \leq b \leq p$

$$-\frac{\partial^2 L(\beta)}{\partial \beta_a \partial \beta_b} = \sum_i \frac{x_{ia} x_{ib} n_i \exp(\sum_j \beta_j x_{ij})}{\left[1 + \exp(\sum_j \beta_j x_{ij})\right]^2} = \sum_i x_{ia} x_{ib} n_i \pi_i (1 - \pi_i).$$

•

$$-\left[\frac{\partial^2 L(\beta)}{\partial \beta_i \partial \beta_j}\right]_{i,j=1}^p = \mathbf{X}^T \text{diag}[n_1 \pi_1 (1 - \pi_1), \dots, n_N \pi_N (1 - \pi_N)] \mathbf{X}.$$

W tych wzorach $L(\beta)$ jest logarytmem funkcji wiarygodności w modelu regresji logistycznej z p zmiennymi objaśniającymi, a $\mathbf{X} = [x_{ij}]$ jest macierzą $N \times p$ zawierającą N różnych wartości $\mathbf{x}_1, \dots, \mathbf{x}_N$ wektora zmiennych objaśniających zaobserwowanych w próbie rozmiaru n . Ponadto, n_i oznacza liczbą obserwacji, dla których $(X_1, \dots, X_p) = \mathbf{x}_i$ (dane zgrupowane).