

1 Zajęcia laboratoryjne 12. – nieparametryczna estymacja funkcji regresji

Regressogram

Ustalić: $r(x) = \sin(2\pi x) + 2x$, $n = 200$, $\sigma = 0.2$, a $x_1, x_2, \dots, x_n$ i.i.d. $U(0, 1)$.

1. Wygenerować n obserwacji $Y_1, \dots, Y_n$ postaci

$$Y_i = r(x_i) + \varepsilon_i,$$

gdzie $\varepsilon_1, \dots, \varepsilon_n$ są i.i.d. $N(0, \sigma^2)$.

2. Podzielić przedział $[0, 1]$ na $m = 20$ równych podprzedziałów $B_1, \dots, B_m$ o długości $h = 1/m$ i skonstruować **regressogram**

$$\hat{r}_n(x) = \frac{1}{k_j} \sum_{\{i: x_i \in B_j\}} Y_i, \quad x \in B_j,$$

gdzie $k_j = \#\{i : x_i \in B_j\}$ jest liczbą obserwacji w przedziale B_j .

3. Umieścić na jednym wykresie trzy zestawy punktów:

$$\{(x_i, Y_i)\}, \quad \{(x_i, r(x_i))\}, \quad \{(x_i, \hat{r}_n(x_i))\}.$$

Estymator Nadaraya–Watsona

Ustalić: $r(x) = \frac{\cos(5\pi x)}{1 + 10x^2}$, $n = 200$, $\sigma = 0.3$, $x_i = i/n$, $i = 1, \dots, n$.

1. Wygenerować n obserwacji $Y_1, \dots, Y_n$ postaci

$$Y_i = r(x_i) + \varepsilon_i,$$

gdzie $\varepsilon_1, \dots, \varepsilon_n$ są i.i.d. $N(0, \sigma^2)$.

2. Skonstruować estymator jądrowy Nadaraya–Watsona (N-W) funkcji regresji r , stosując jądro gaussowskie i szerokości pasma h . Dla $h \in \{0.02, 0.05, 0.1, 0.2\}$ umieścić na jednym wykresie:

- punkty obserwacji (x_i, Y_i) ,
- wykres prawdziwej funkcji r ,
- wykresy estymatorów $\hat{r}_{NW}$ odpowiadających kolejnym wartościom h (każdy w innym kolorze lub stylu linii).

Dołączyć legendę opisującą: punkty obserwacji, funkcję rzeczywistą oraz estymatory.

3. Zaimplementować procedurę leave-one-out cross-validation (LOOCV) do wyboru optymalnej szerokości pasma h dla estymatora N-W.

- (a) Narysować wykres prawdziwej funkcji r oraz wykres estymatora NW z optymalną wartością h wybraną metodą LOOCV.

4. Dla ustalonej szerokości pasma h , przyjętej jako wartość wybrana metodą LOOCV dla jądra gaussowskiego, zbadać zachowanie estymatora Nadaraya–Watsona w zależności od zastosowanego jądra:

- gaussowskie,
- Epanechnikova,
- prostokątne,
- trójkątne.

Umieścić na jednym rysunku wykresy czterech estymatorów $\hat{r}_{NW}$ wraz z funkcją r i porównać gładkość estymatorów oraz ich dopasowanie do funkcji regresji r .