Sprawozdanie 1

Dawid Skowroński

2026-03-11

Wczytujemy dane $(x_1, y_1), ..., (x_n, y_n)$ z pliku "lab 1 i 2.xlsx".

```
# Wczytanie danych

dane <- as.data.frame(read_excel("lab-1-i-2.xlsx"))
```

Dane zawierają 200 obserwacji.

1 Zadanie 1

Wskaźnik	x	y
Min	0.0228	2024.6866
Max	9.9776	2056.6616
Q1	2.3186	2032.6510
Mediana	4.8834	2040.8819
Q3	7.5106	2048.0650
Średnia	4.8930	2040.6381
Wariancja	8.3691	75.9764
Odch. std.	2.8929	8.7164

Tabela przedstawia wskaźniki numeryczne dla każdej ze zmiennych x oraz y.

Zauważalny jest równomierny rozkład wartości zmiennej x między minimum a maksimum wartości zmiennej x.

2 Zadanie 2

Tworzymy wykres rozrzutu zmiennych x oraz y. Wyznaczamy także próbkowy współczynnik korelacji tych zmiennych.

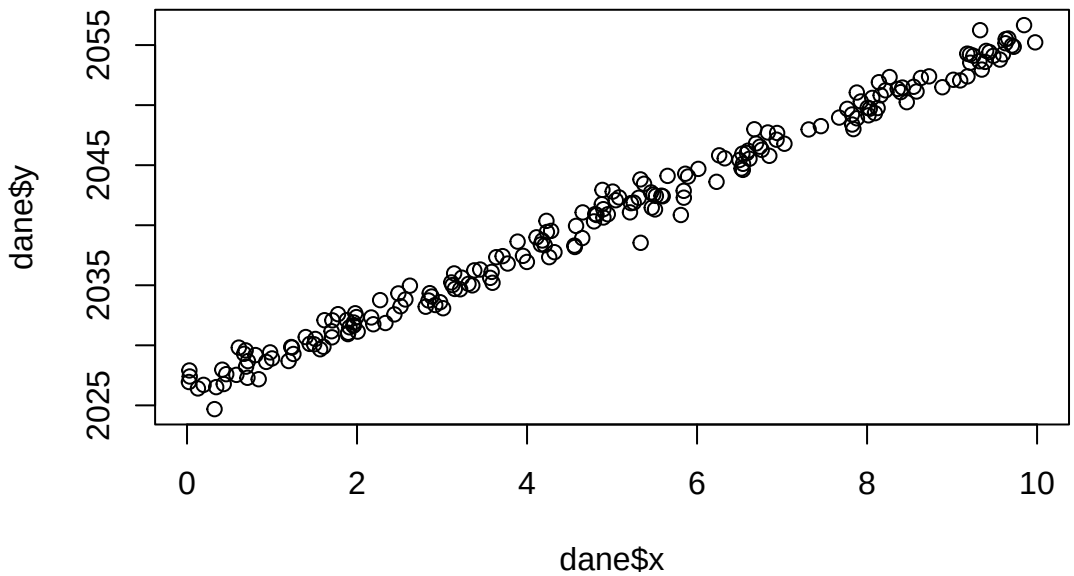

Wykres rozrzutu zmiennych y i x pokazuje wyraźną zależność liniową między zmiennymi. Punkty układają się wzdłuż funkcji prostej, co sugeruje że liniowy model regresji będzie dobrze dopasowany do danych. Potwierdza to także wartość próbkowego współczynnika korelacji (0.9945777), która jest bardzo bliska 1, tzn. w danych występuje silna dodatnia zależność liniowa. Nie zauważamy także istotnej zmienności wariancji. Zatem, rozpatrywany w tym przykładzie model regresji liniowej ma sens. Występuje niezerowy trend, co było widoczne na wykresie rozrzutu.

3 Zadanie 3

Za pomocą metody najmniejszych kwadratów wyznaczamy wartości estymatorów $\widehat{\beta_0}$ i $\widehat{\beta_1}$ parametrów β_0 i β_1.

```
sr_x <- mean(dane$x)
sr_y <-  mean(dane$y)

est_beta_1 <-  sum((dane$x-sr_x)*(dane$y - sr_y))/ sum((dane$x - sr_x)^2)
est_beta_0 <- sr_y - est_beta_1*sr_x
```

Wartości estymatorów wynoszą odpowiednio:

- $\widehat{\beta_0} = 2025.9754064$,
- $\widehat{\beta_1} = 2.9966636$.

4 Zadanie 4

Wyznaczamy wartość estymatora $\widehat{\sigma^2} = \frac{\sum_{i=1}^{n}(y_i - \widehat{y_i})^2}{n-2}$ parametru σ^2.

W tym celu musimy najpierw wyznaczyć prognozową przez model wartość zmiennej objaśnianej y, tzn.

$$\widehat{y_i} = \widehat{\beta_0} + \widehat{\beta_1} x_i.$$

```
y_est <- est_beta_0 + est_beta_1 * dane$x
```

```
est_sigma_kw <- sum((dane$y - y_est)^2)/(length(dane$x)-2)
```

Wartość estymatora $\widehat{\sigma^2}$ wynosi 0.8258558.

5 Zadanie 5

Weryfikujemy hipotezę $H_0 : \beta_1 = 0$ przy hipotezie alternatywnej $H_1 : \beta_1 \neq 0$ na poziomie istotności $\alpha = 0.05$.

```
SE_beta_1_kw <- est_sigma_kw/sum((dane$x - sr_x)^2)

statystyka_T <- est_beta_1/sqrt(SE_beta_1_kw)

p_value <- 2*(1 - pt( abs(statystyka_T), length(dane$x) - 2) )
```

Wartość statystyki testowej T wynosi 134.5712938, natomiast p-wartość $= 0$. Wartość poziomu krytycznego jest niższy od zadanego poziomu istotności, zatem odrzucamy hipotezę zerową. Oznacza to że wartość estymatora $\widehat{\beta_1}$ jest istotnie różna od zera.

6 Zadanie 6

Tworzymy realizację przedziału ufności dla β_1 na poziomie ufności 0.99.

```
T_upper <-  est_beta_1 +  qt(1- 0.01/2, length(dane$x) - 2 )*sqrt(SE_beta_1_kw)
T_lower <- est_beta_1 - qt(1- 0.01/2, length(dane$x) - 2 )*sqrt(SE_beta_1_kw)
```

Dolna granica realizacji przedziału wynosi 2.9387465, natomiast górna ma wartość 3.0545808.

7 Zadanie 7

Dla $x_0 = 1$ wyznaczamy za pomocą modelu wartość prognozowaną $\widehat{Y}(x_0)$. Wyznaczamy także realizację przedziału ufności na poziomie ufności 0.99 dla $Y(x_0)$.

```
x0 <- 1
est_Y_x0 <- est_beta_0 + est_beta_1*x0
```

Otrzymujemy wartość prognozowaną $\widehat{Y}(1) = 2028.97207$.

```
# Realizacja przedziału ufności

SE_kw_estY_Y <- est_sigma_kw*(1 + 1/nrow(dane) + (x0 - sr_x)^2/sum((dane$x - sr_x)^2) )

T_Y_upper <- est_Y_x0 +  qt(1- 0.01/2, length(dane$x) - 2 )*sqrt(SE_kw_estY_Y)
T_Y_lower <- est_Y_x0 -  qt(1- 0.01/2, length(dane$x) - 2 )*sqrt(SE_kw_estY_Y)
```

Dolna granica realizacji przedziału dla $Y(x_0)$ wynosi 2026.5918669, natomiast górna ma wartość 2031.3522731.

8 Zadanie 8

Tworzymy histogram i wykres kwantylowy dla rezyduów. Rysujemy także wykresy rozrzutu dla par $(\widehat{y_1}, e_1), ..., (\widehat{y_n}, e_n)$ oraz $(x_1, e_1), ..., (x_n, e_n)$, gdzie $e_i := y_i - \widehat{y_i}$.

```
# Wyznaczamy reszty modelu
rezydua <- dane$y - y_est
```

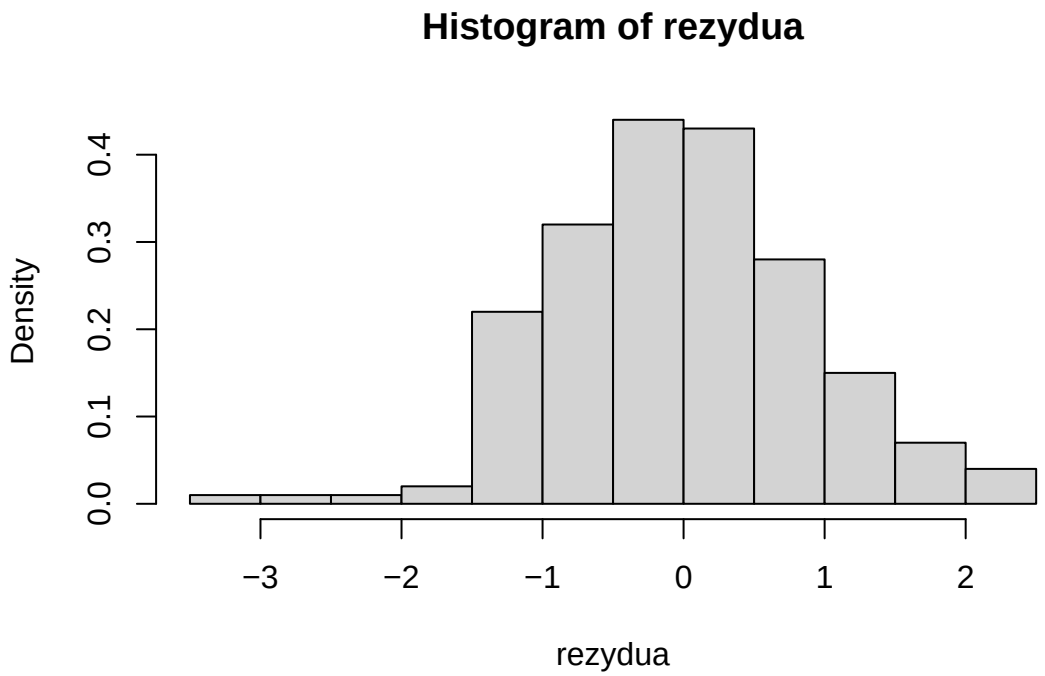

Analizując histogram dla rezyduów, możemy mieć wątpliwości co do normalności rozkładu. Rozkład wydaje się nie być idealnie symetryczny. Widoczna jest także lekka prawostronna skośność. Jednak może to wynikać ze zbyt małego rozmiaru próby (200). Zatem, histogram może nie być najbardziej odpowiednim narzędziem do weryfikacji.

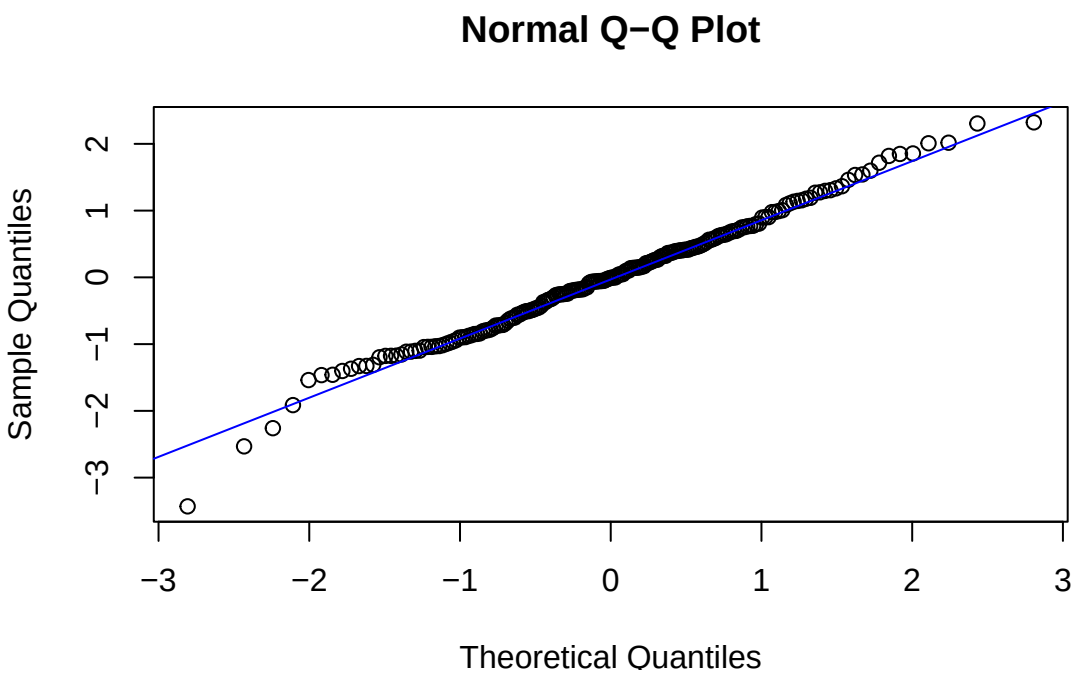

Z wykresu można odczytać, że punkty układają się dość blisko linii $y = x$. Kwantyle rezyduów układają się wzdłuż linii wyznaczonej przez kwantyle teoretyczne rozkładu normalnego, zatem, rozkład realizacji próby jest zbliżony do rozkładu normalnego.

Wykonujemy wykres rozrzutu dla par $(\widehat{y_1}, e_1), ..., (\widehat{y_n}, e_n)$.

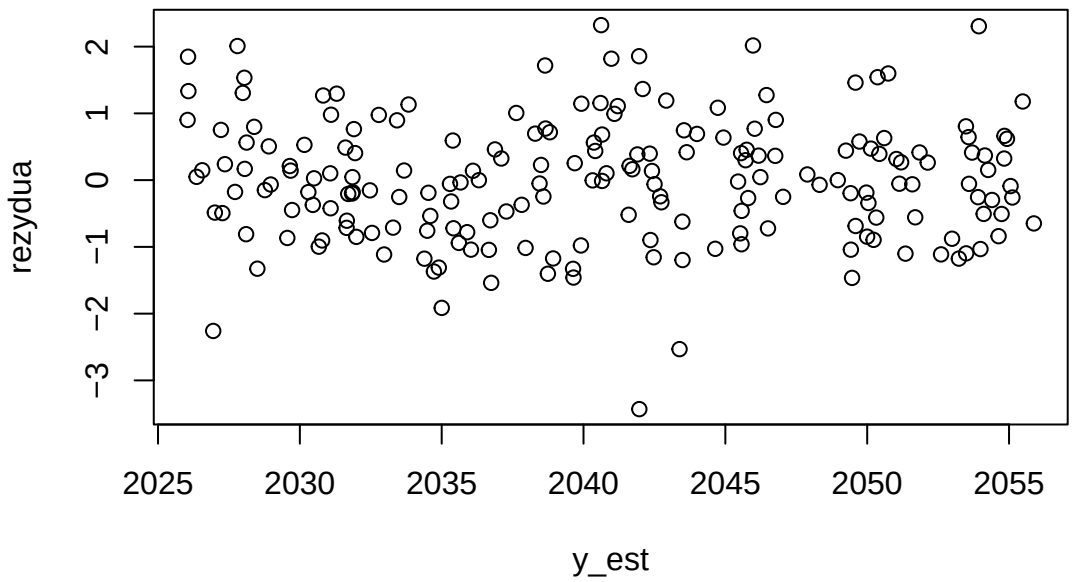

Wykonujemy także wykres rozrzutu dla par $(x_1, e_1), ..., (x_n, e_n)$.

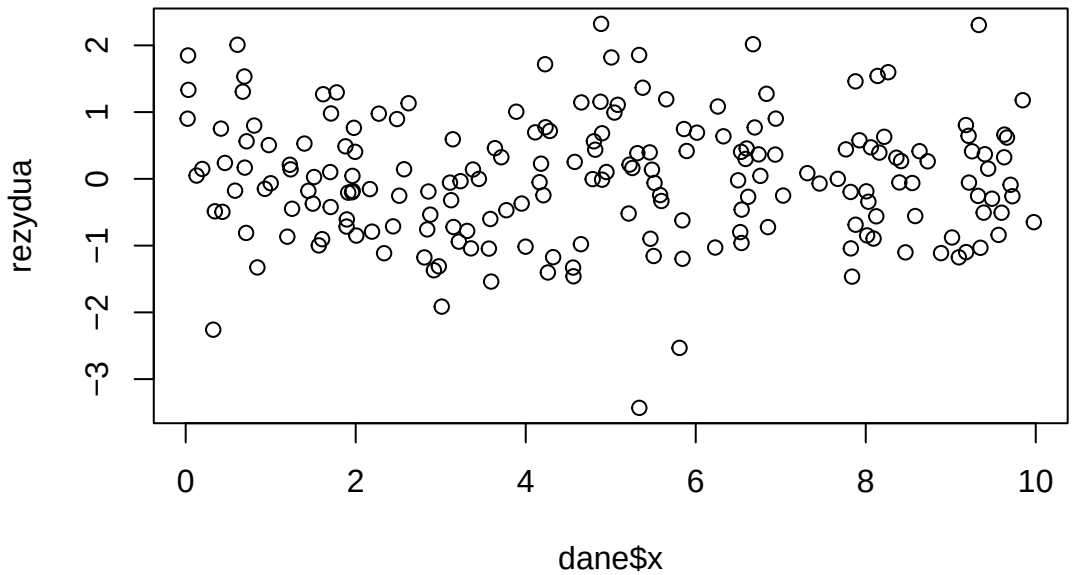

Na wykresach rozrzutu nie zauważamy żadnych regularnych wzorców, struktur czy trendu. Dane są rozproszone wokół osi Ox, co spełnia teoretyczne założenia poprawności modelu regresji.

Podsumowując, na podstawie rysunków nie mamy zastrzeżeń co do braku spełnienia któregokolwiek z założeń modelu.

9 Zadanie 9

Modyfikujemy dane poprzez pomnożenie ostatniej wartości zmiennej objaśnianej przez 10. Ponownie wyznaczamy estymatory najmniejszych kwadratów parametrów β_0 oraz β_1 i porównujemy je z poprzednio otrzymanymi estymatorami.

```
nowe_dane <- dane
nowe_dane$y[nrow(dane)] <- dane$y[nrow(dane)]*10
```

```r
nowe_sr_x <- mean(nowe_dane$x)
nowe_sr_y <-  mean(nowe_dane$y)

nowe_est_beta_1 <- sum((nowe_dane$x-nowe_sr_x)*(nowe_dane$y - nowe_sr_y))/
                        sum((nowe_dane$x - nowe_sr_x)^2)
nowe_est_beta_0 <- nowe_sr_y - nowe_est_beta_1*nowe_sr_x
```

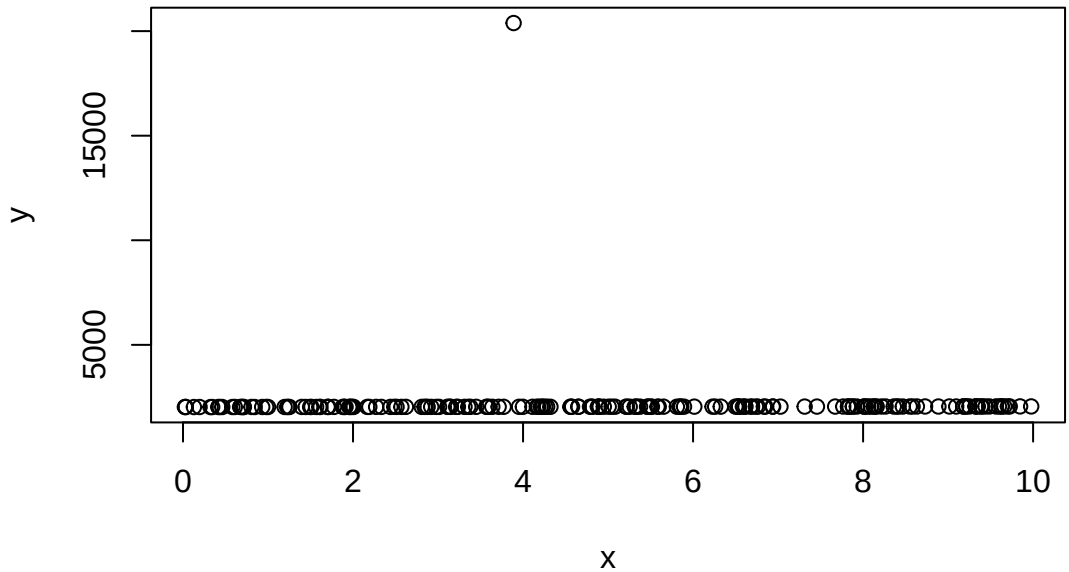

Nowe estymatory wynoszą odpowiednio:

- $\tilde{\beta}_0$ = 2171.8248487 - bezwględna różnica względem poprzedniego estymatora wynosi $|\tilde{\beta}_0$ - $\widehat{\beta_0}| =$ 145.8494424,
- $\tilde{\beta}_1$ = -8.0621601 - bezwględna różnica względem poprzedniego estymatora wynosi $|\tilde{\beta}_1$ - $\widehat{\beta_1}| =$ 11.0588237.

Wartości estymatorów istotnie się zmieniły. Możemy zauważyć znaczny wzrost wartości estymatora $\tilde{\beta}_0$ względem estymatora $\widehat{\beta_0}$ oraz zmianę znaku estymatora $\widehat{\beta_1}$ na ujemny ($\tilde{\beta}_1$ przyjmuje także znacznie mniejszą wartość), przez co trend w modelu zmienił się z rosnącego na malejący.

Zatem zmiana wartości zmiennej objaśnianej dla jednej wartości, spowodowała istotną zmianę wartości współczynników modelu.

10 Zadanie 10

Wykonujemy analogiczną analizę, jak w poprzednich zadaniach, dla danych wygenerowanych. Generujemy realizacje próby $x_1, ..., x_n$ z rozkładu $U(-2, 2)$.

```r
set.seed(282241)

n=200
b0 = 1
b1 = 2
x <- runif(n,-2,2)
epsilon <- rnorm(n, mean = 0, sd = 0.1)

# Generujemy obserwacje
y_gen <- b0 + b1*x + epsilon
```

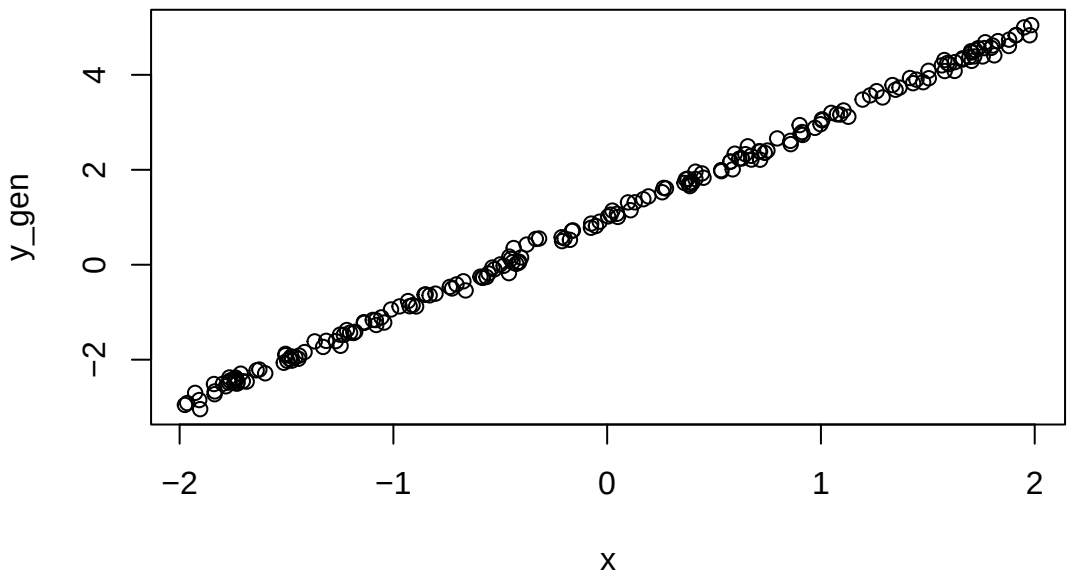


```
gen_sr_x <- mean(x)
gen_sr_y <- mean(y_gen)

gen_est_beta_1 <-  sum((x-gen_sr_x)*(y_gen - gen_sr_y))/ sum((x - gen_sr_x)^2)
gen_est_beta_0 <- gen_sr_y - gen_est_beta_1*gen_sr_x
```

Wartości estymatorów wynoszą odpowiednio:

- $\widehat{\beta_0} = 0.995751$,
- $\widehat{\beta_1} = 1.9983503$.

Oba estymatory mają wartości bardzo zbliżone do wartości odpowiednich parametrów $\beta_0 = 1$ i $\beta_1 = 2$.

Przeprowadzamy analizę dla różnych wartości odchylenia standardowego ($\sigma = 0.5$ oraz $\sigma = 1$) i porównujemy wartości estymatorów oraz współczynnika R^2.

Tworzymy funkcję `generuj_obserwacje()`, która wyznacza estymatory $\widehat{\beta_0}$, $\widehat{\beta_1}$ na podstawie wygenerowanych danych, a także wartość współczynnika R^2. Jako parametr podajemy wartość odchylenia standardowego σ.

```
set.seed(282241)

generuj_obserwacje <- function(sigma){

n=200

b0 = 1
b1 = 2
x <- runif(n,-2,2)
epsilon <- rnorm(n, mean = 0, sd = sigma)

# Wygeneruj obserwacje
y_gen <- b0 + b1*x + epsilon

plot(x,y_gen)

gen_sr_x <- mean(x)
gen_sr_y <- mean(y_gen)
```

```r
gen_est_beta_1 <-  sum((x-gen_sr_x)*(y_gen - gen_sr_y))/ sum((x - gen_sr_x)^2)
gen_est_beta_0 <- gen_sr_y - gen_est_beta_1*gen_sr_x

y_pred <- gen_est_beta_0 + gen_est_beta_1*x

SSE <- sum((y_gen-y_pred)^2)

SST <- sum((y_gen - gen_sr_y)^2)

R_kw <- 1- SSE/SST

return(c(gen_est_beta_0, gen_est_beta_1, R_kw))
}
```

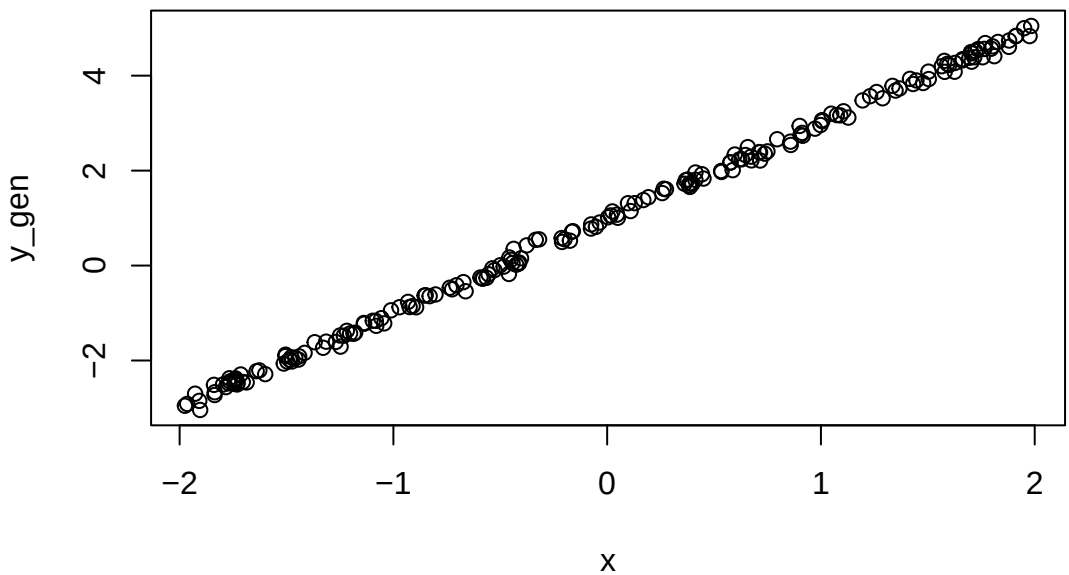

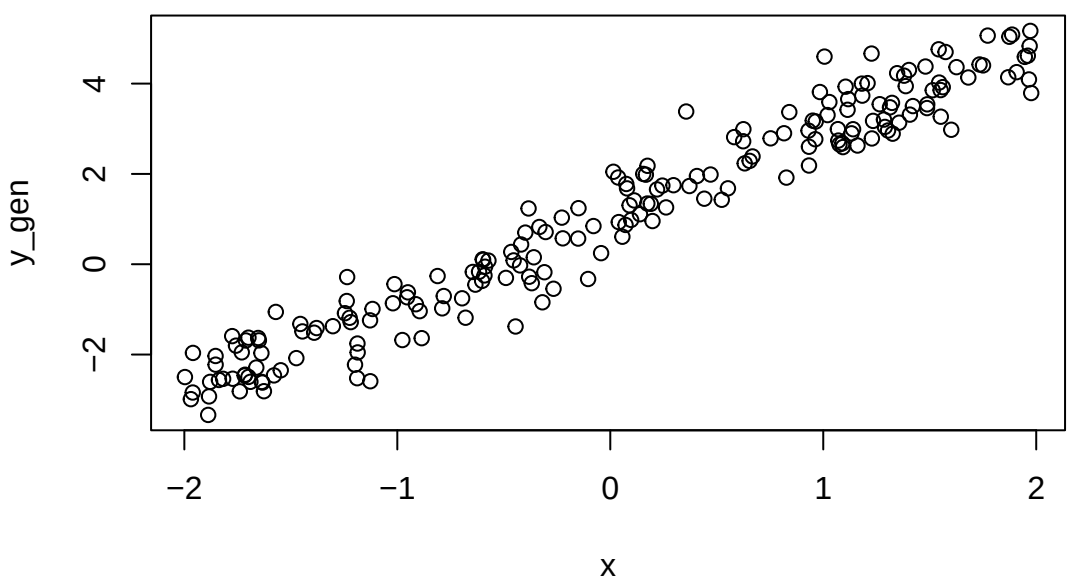

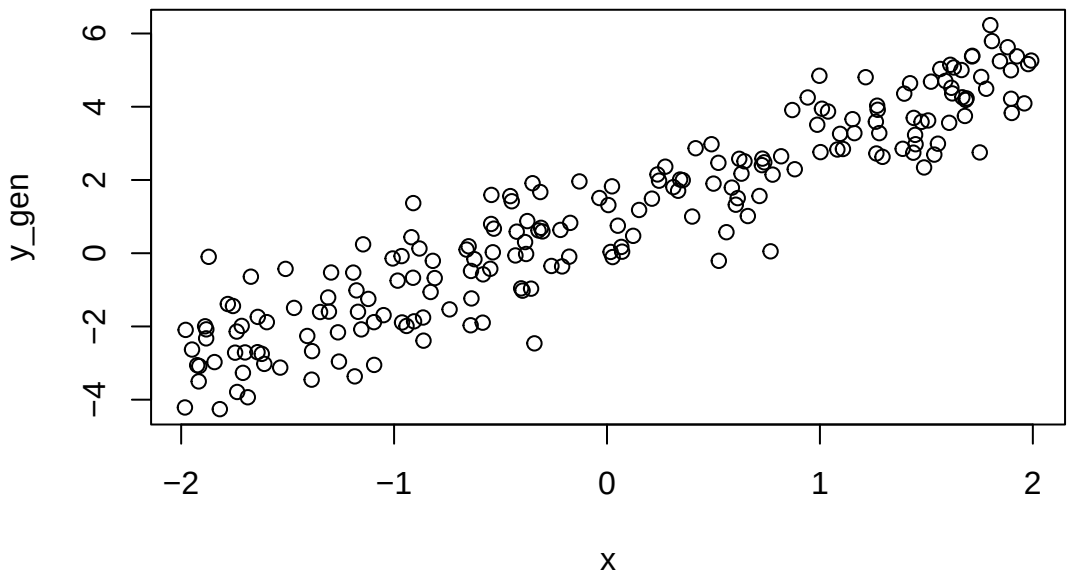

Z wykresów możemy odczytać, ze wraz ze wzrostem wariancji, chmura punktów jest bardziej rozproszona wokół funkcji liniowej.

Dla $\sigma = 0.5$ wyniki są następujące:

- $\widehat{\beta_0} = 1.0163605$,
- $\widehat{\beta_1} = 1.9400846$,
- $R^2 = 0.948941$.

Dla $\sigma = 1$ wyniki są następujące:

- $\widehat{\beta_0} = 0.9437055$,
- $\widehat{\beta_1} = 2.0216493$,
- $R^2 = 0.8738699$.

Wraz ze wzrostem σ^2 zauważalny jest spadek wartości R^2 oraz precyzji wyznaczonych estymatorów. Oba otrzymane wyniki są gorsze w porównaniu z wynikami dla $\sigma = 0.1$. W przypadku estymatora $\widehat{\beta_0}$ wynik dla $\sigma = 0.5$ jest bliższy $\beta_0 = 1$ niż przypadku $\sigma = 1$. Jednak dla estymatora $\widehat{\beta_1}$ jego wartość jest bliższa wartości $\beta_1 = 2$ dla $\sigma = 1$ niż dla $\sigma = 0.5$ (może to być efekt losowy, wynikający z generowania danych z konkretnego ziarna).