Sprawozdanie 2

Dawid Skowroński

2026-03-25

Wczytujemy dane z pliku "regresja wielokrotna 2026.xlsx".

```
dane <- as.data.frame(read_excel("regresja wielokrotna 2026.xlsx"))

n <- nrow(dane)
X <- dane[,-ncol(dane)]
Y <- dane[, ncol(dane)]
czy_obs_na <- sum(is.na(dane))
```

Dane zawierają 200 obserwacji. W danych występuje 0 obserwacji brakujących.

1 Zadanie 1

Wykonujemy wykresy rozrzutu dla par (Y, X_i) oraz (X_i, X_j). W tym celu możemy skorzystać z funkcji `pairs()`.

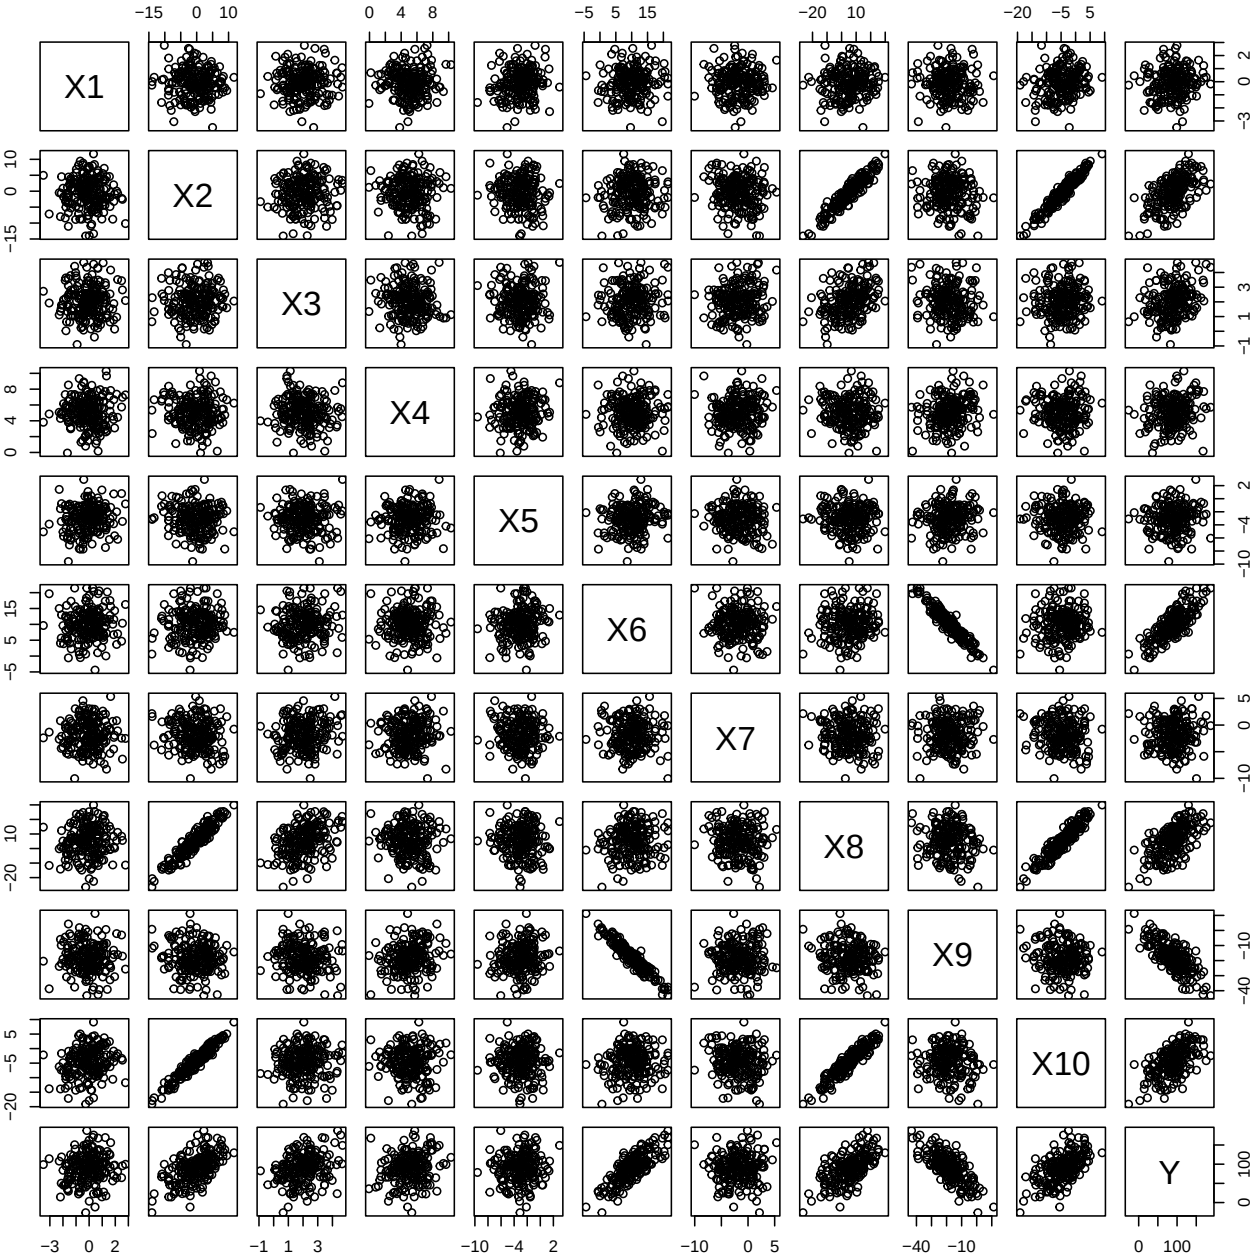

a) Z wykresów rozrzutu możemy odczytać, że zmienna X_6 wykazuje wyraźny liniowy związek ze zmienną objaśnianą Y. Dla zmiennych X_8, X_9 i X_{10} obserwujemy istotny (lecz mniej wyraźny) liniowy związek ze zmienną objaśnianą Y. Zatem, zmienne X_6, X_8, X_9 i X_{10} mogą mieć liniowy wpływ na zmienną objaśnianą Y.

b) Dla par (X_2, X_8), (X_2, X_{10}), (X_6, X_9) oraz (X_8, X_{10}) obserwujemy silną liniową korelację zmiennych. Zatem, występuje problem współliniowości w danych.

c) Na podstawie wykresów, możemy stwierdzić występowanie obserwacji odstających m.in. dla par (X_6, Y), (X_9, Y), (X_2, Y).

2 Zadanie 2

Wyznaczamy macierz korelacji dla zmiennych $Y, X_1, ..., X_{10}$.

```r
# Macierz korelacji
mac_korelacji <- round(cor(dane),3)
```

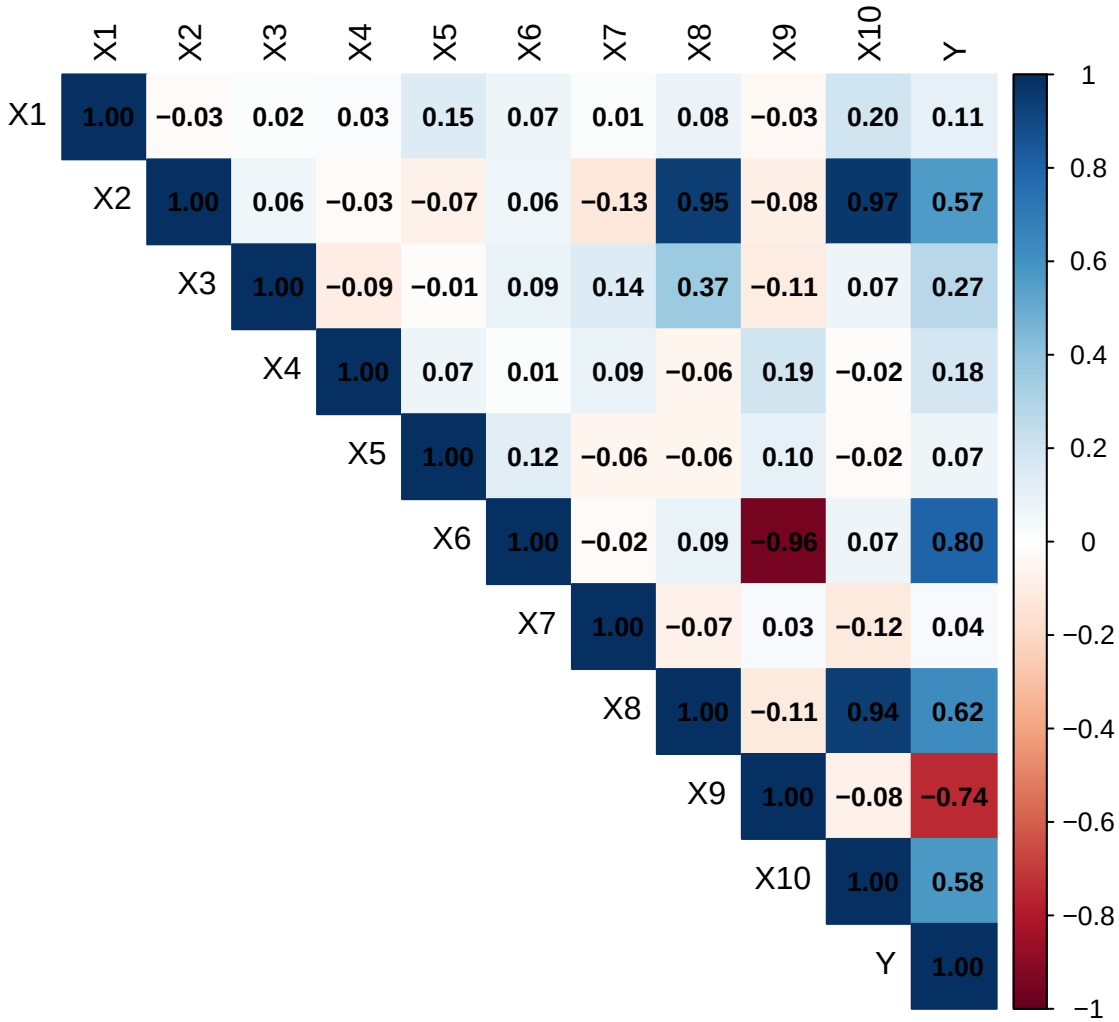

Obserwujemy wysoką wartość korelacji próbkowej dla par (X_2, X_8), (X_2, X_{10}), (X_8, X_{10}) oraz (X_6, Y). Wartości bliskie 0.6 otrzymano dla par (X_2, Y), (X_8, Y), (X_{10}, Y). Wartości bliskie -1 otrzymano dla par (X_6, X_9) oraz (X_9, Y).

Na tej podstawie możemy wyciągnąć podobne wnioski jak w przypadku zadania 1. Wartości współczynnika korelacji próbkowej potwierdzają analizę opartą na wykresach rozrzutu.

3 Zadanie 3

Tworzymy model regresji liniowej dla zmiennej objaśnianej Y i zmiennych objaśniających $X_1, ..., X_{10}$.

```r
model_pelny <- lm(Y~. , data = dane)
estymatory_beta <- coef(model_pelny)

opis_modelu <- summary(model_pelny)
wart_F <- opis_modelu$fstatistic
p_F <- pf(wart_F, opis_modelu$df[1], opis_modelu$df[2],
            lower.tail = FALSE)
p_wart <- p_F[1]
```

```r
# R^2 i skorygowany R^2
R_kw <- summary(model_pelny)$r.squared
adj_R_kw <- summary(model_pelny)$adj.r.squared
```

a) W tabeli przedstawione zostały wartości estymatorów najmniejszych kwadratów $\widehat{\beta}$. Możemy zauważyć, wszystkie wartości są istotnie różne od zera.

Zmienna	Wartość estymatora
(Intercept)	-0.36633
X1	1.31223
X2	2.48179
X3	3.64392
X4	4.41298
X5	0.48266
X6	5.10263
X7	1.05125
X8	0.83739
X9	-0.43897
X10	-0.15381

b) Wykonujemy test o braku liniowego wpływu zmiennych objaśniających na zmienną objaśnianą. Testujemy hipotezę $H_0 : \beta_1 = ... = \beta_{10} = 0$ przeciwko hipotezie alternatywnej $H_1 : \exists i \in 1, ..., 10 \quad \beta_i \neq 0$. Otrzymujemy p-wartość testu F równą $6.2348967 \times 10^{-301}$. Jest to wartość mniejsza od każdego sensownego poziomu istotności α (w szczególności $\alpha = 0.05$), zatem powinniśmy odrzucić hipotezę H_0. Oznacza to że w modelu przynajmniej jedna ze zmiennych $X_1, ..., X_{10}$ ma liniowy wpływ na Y.

c) Wartość współczynnika R^2 wynosi 0.999386, natomiast wartość skorygowanego współczynnika R^2 wynosi 0.9993536. W obu przypadkach otrzymujemy wartość bardzo bliską 1. Sugeruje to bardzo dobre wyjaśnienie zmienności danych i dopasowanie modelu do obserwacji.

4 Zadanie 4

Zajmujemy się problemem współliniowości. W tym celu dla każdej ze zmiennych objaśniających wyznaczamy wskaźnik podbicia wariancji VIF i analizujemy ich wartości. Posłużymy się funkcją `vif()` z pakietu `car`.

```r
vif(model_pelny)
```

```
##          X1          X2          X3          X4          X5          X6
##   29.362239 1915.974487  179.758325   28.352135   34.923897  720.656371
##          X7          X8          X9         X10
##    1.084525 1927.368370  743.701111   98.397333
```

```r
X_prosty1 <- X[,-8]

model_prosty1 <- lm(Y~., data = cbind(Y=Y,X_prosty1))
```

Możemy zauważyć, że największa wartość VIF jest osiągana dla X_8 i przekracza wartość 10. Zatem, tworzymy nowy model bez zmiennej X_8.

```r
vif(model_prosty1)
```

```
##         X1         X2         X3         X4         X5         X6         X7
##   5.673484  91.309968   1.056029  28.080197  34.600497 713.894340   1.066055
##         X9        X10
## 736.536504  94.608677
```

```r
X_prosty2 <- X_prosty1[,-8]

model_prosty2 <- lm(Y~., data = cbind(Y=Y,X_prosty2))
```

Największa wartość VIF jest osiągana dla X_9 i przekracza wartość 10. Zatem, tworzymy kolejny, nowy model bez zmiennej X_9.

```r
vif(model_prosty2)
```

```
##        X1        X2        X3        X4        X5        X6        X7       X10
##  5.661631 91.259379  1.052635  1.031352  1.070885  1.037012  1.062009 94.552938
```

```r
X_prosty3 <- X_prosty2[,-8]
```

Największa wartość VIF jest osiągana dla X_{10} i przekracza wartość 10. Zatem, tworzymy kolejny, nowy model bez zmiennej X_{10}.

```r
model_prosty3 <- lm(Y~., data = cbind(Y=Y,X_prosty3))
vif(model_prosty3)
```

```
##       X1       X2       X3       X4       X5       X6       X7
## 1.026188 1.035339 1.050014 1.026707 1.052000 1.032656 1.059852
```

W modelu bez zmiennych X_8, X_9, X_{10} nie obserwujemy już wartości VIF powyżej 10. Rozpatrujemy zatem w kolejnych zadaniach uproszczony model bez tych zmiennych.

5 Zadanie 5

Sprawdzamy, czy w danych występują obserwacje wpływowe. W tym celu analizujemy wpływy kolejnych obserwacji h_{11}, h_{nn} (główna przekątna macierzy H), studentyzowane rezydua r_i oraz odległość Cook'a D_i.

Sprawdzamy na podstawie h_{ii}, czy występują obserwacje odstające względem X. Obserwacje i-tą uznajemy za odstającą ze wględu na X, gdy $h_{ii} >= \frac{2p}{n}$.

Rozpatrujemy studentyzowane rezydua. Uznajemy i-tą obserwację za odstającą ze względu na Y, gdy $|r_i| > 2$.

W przypadku odległości Cook'a, obserwację i-tą uznajemy za wpływową, gdy $D_i > \frac{4}{n-p}$.

```r
# Liczba obserwacji
n <- nrow(dane)

# Ślad macierzy
p <- length(coef(model_prosty3))

# Elementy na diagonali macierzy H
lev <- hatvalues(model_prosty3)
# Odległość Cook'a
cook <- cooks.distance(model_prosty3)
# Studentyzowane rezydua
rstud <- rstudent(model_prosty3)

prog.lev <- 2*p/n
prog.cook <- 4/(n-p)
prog.rstud <- 2

indeks.lev <- which(lev>prog.lev)
indeks.cook <- which(cook>prog.cook)
indeks.rstud <- which(abs(rstud)>prog.rstud)
```

```r
indeksy.do.usuniecia <- sort(unique(c(indeks.lev,
                                      indeks.cook,
                                      indeks.rstud)))

dane_nowe <- dane[-indeksy.do.usuniecia,]
```

Obserwacje, które należy usunąć mają indeksy: 5, 31, 43, 51, 53, 67, 71, 73, 104, 129, 143, 147, 149, 154, 167, 181, 195.

Na wykresie oznaczono indeksami obserwacje, które uznano za wpływowe (na podstawie odległości Cook'a).

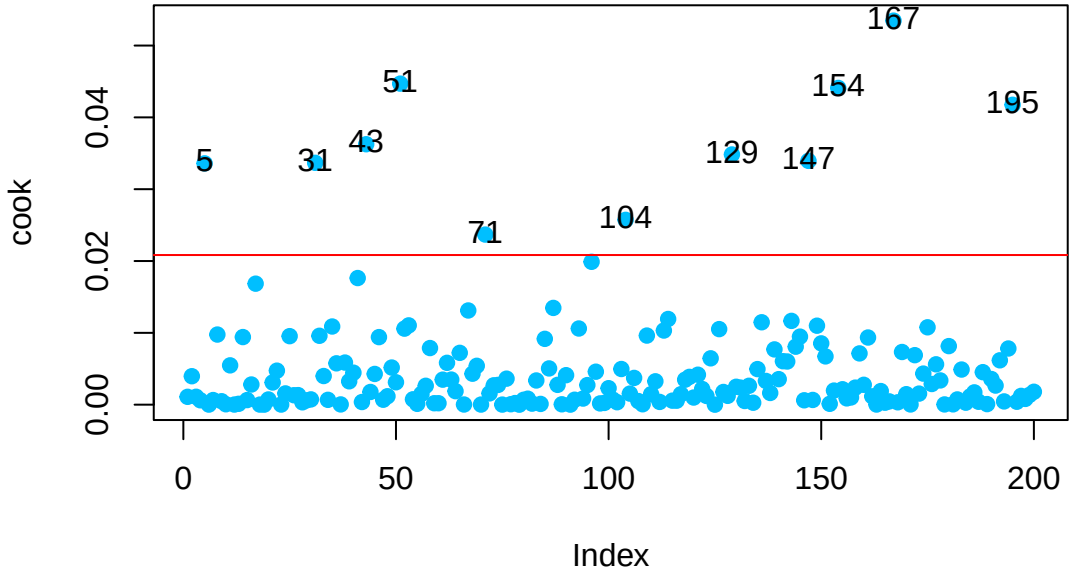

Na wykresie oznaczono indeksami obserwacje, które uznano za odstające (na podstawie wpływów h_{ii}).

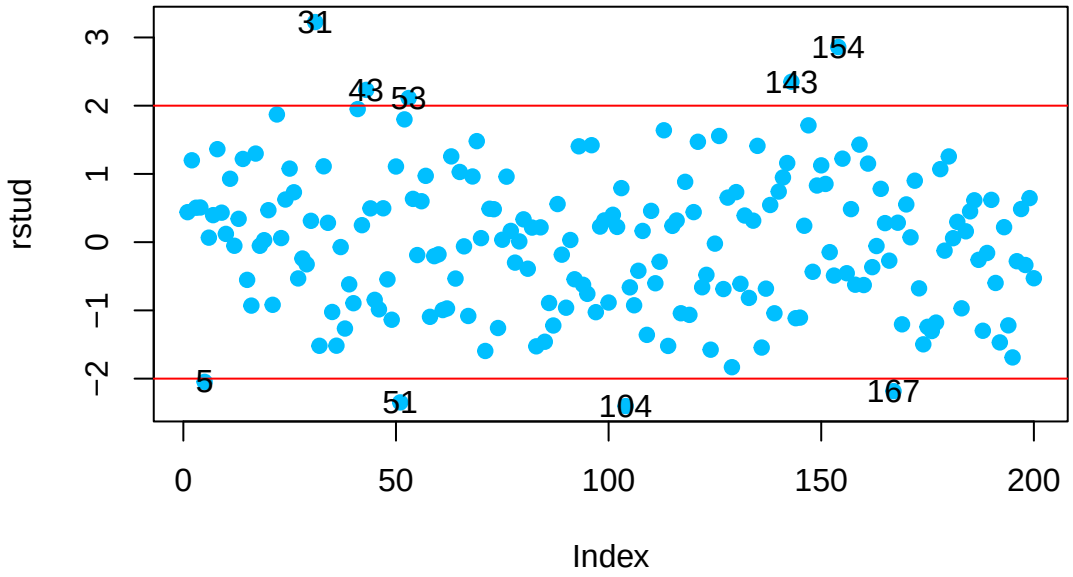

Na wykresie oznaczono indeksami obserwacje, które uznano za odstające (na podstawie studentyzowanych rezyduów).

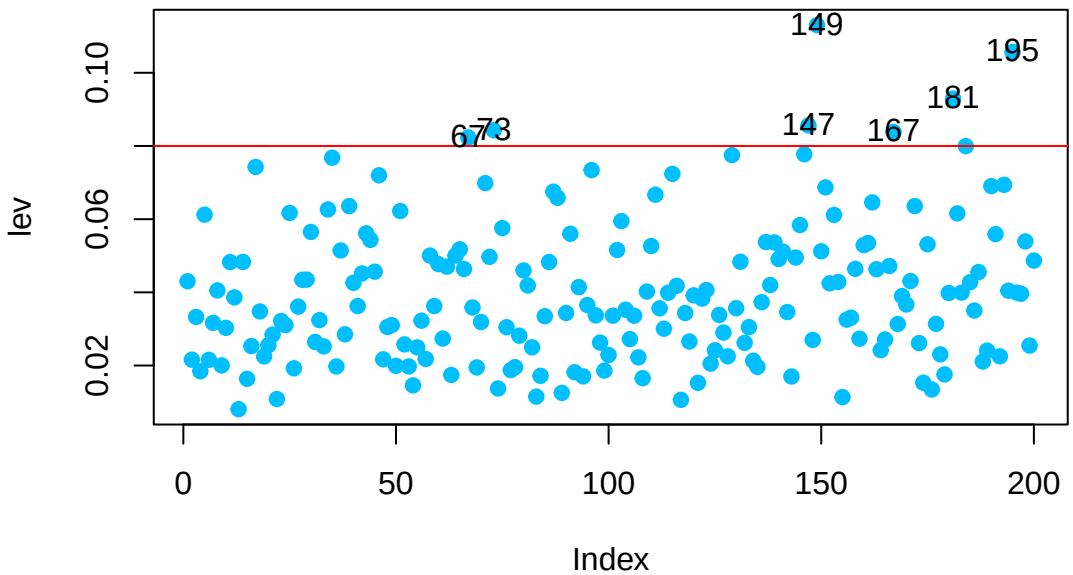

6 Zadanie 6

Na podstawie analizy z poprzednich zadań tworzymy nowy, uproszczony model.

```
X_nowe <- X_prosty3[-indeksy.do.usuniecia,]

Y_nowe <- Y[-indeksy.do.usuniecia]
Y_nowe <- as.matrix(Y_nowe)

model_nowy <- lm(Y_nowe~., data = cbind(Y_nowe = Y_nowe,X_nowe))

nowe_est_beta <- coefficients(model_nowy)


opis_modelu <- summary(model_pelny)
wart_F_nowy <- opis_modelu$fstatistic
p_F_nowy <- pf(wart_F_nowy,
          opis_modelu$df[1],
          opis_modelu$df[2],
          lower.tail = FALSE)
p_wart <- p_F_nowy[1]


R_kw_nowe <- summary(model_nowy)$r.squared
adj_R_kw_nowe <- summary(model_nowy)$adj.r.squared
```

a) W tabeli przedstawione są wartości estymatorów najmniejszych kwadratów dla nowego modelu.

Zmienna	Wartość estymatora
(Intercept)	-0.16717
X1	2.01705
X2	4.00170
X3	6.24498
X4	4.00819

Zmienna	Wartość estymatora
X5	0.02760
X6	5.97980
X7	1.03848

b) Ponownie przeprowadzamy test F, p-wartość wynosi $6.2348967 \times 10^{-301}$. Jest to wartość mniejsza od każdego sensownego poziomu istotności α (w szczególności $\alpha = 0.05$), zatem powinniśmy odrzucić hipotezę H_0. Oznacza to że w modelu uproszczonym przynajmniej jedna ze zmiennych objaśniających ma liniowy wpływ na Y.

c) Wartość współczynnika R^2 wynosi 0.999487, natomiast wartość skorygowanego współczynnika R^2 wynosi 0.9994665. Ponownie, są to wartości bardzo bliskie 1. Otrzymaliśmy nieznacznie większe wartości względem modelu ze wszystkimi zmiennymi, oznacza to że uproszczony model jest nieznacznie lepiej dopasowany do danych.