Sprawozdanie 3

Dawid Skowroński

2026-04-15

Korzystamy z danych otrzymanych po analizie zbioru „regresja wielokrotna.xlsx” ze sprawozdania 2.

Dane zawierają 183 wierszy oraz 8 kolumn. Zawierają one zmienne objaśniające $X_1, X_2, ..., X_7$ oraz zmienną objaśnianą Y.

0.1 Zadanie 1

Wykorzystujemy regresję krokową z kryterium AIC, aby wybrać najlepszy model regresji M (według kryterium AIC).

```
model.min <- lm(Y~1, data = dane.nowe)
model.max <- lm(Y~., data = dane.nowe)

model.aic <- step(object = model.max,
                  scope = list(lower = model.min, upper=model.max),
                  direction = "backward",k=2)
```

```
## Start:  AIC=-66.25
## Y ~ X1 + X2 + X3 + X4 + X5 + X6 + X7
##
##        Df Sum of Sq    RSS     AIC
## - X5    1         1    117  -67.46
## <none>                 117  -66.25
## - X1    1       731    847  294.46
## - X7    1      1195   1312  374.49
## - X3    1      6844   6960  679.85
## - X4    1      8288   8404  714.35
## - X2    1     63879  63996 1085.85
## - X6    1    121923 122040 1203.98
##
## Step:  AIC=-67.46
## Y ~ X1 + X2 + X3 + X4 + X6 + X7
##
##        Df Sum of Sq    RSS     AIC
## <none>                 117  -67.46
## - X1    1       743    861  295.29
## - X7    1      1201   1318  373.30
## - X3    1      6869   6986  678.53
## - X4    1      8291   8409  712.44
## - X2    1     64136  64254 1084.58
## - X6    1    123690 123807 1204.61
```

```
model.aic
```

```
##
```

```
## Call:
## lm(formula = Y ~ X1 + X2 + X3 + X4 + X6 + X7, data = dane.nowe)
##
## Coefficients:
## (Intercept)           X1           X2           X3           X4           X6
##     -0.2635       2.0228       4.0010       6.2412       4.0086       5.9812
##          X7
##      1.0365
```

Możemy zauważyć, że po wyeliminowaniu zmiennej X_5, wartość kryterium AIC zmalała. Zatem, najlepszym modelem, względem kryterium AIC, jest model ze zmiennymi objaśniającymi $X_1, X_2, X_3, X_4, X_6, X_7$. Nie jesteśmy w stanie dalej minimalizować tego kryterium, poprzez usuwanie poszczególnych zmiennych X_i.

Zatem, usuwamy kolumnę 5 z analizowanego zbioru.

```r
dane_aic <- dane.nowe[,-5]
```

0.1.1 podpunkt a

Wyznaczamy estymatory najmniejszych kwadratów $\widehat{\beta}$ modelu M.

Zmienna	Wartość estymatora
(Intercept)	-0.26351
X1	2.02275
X2	4.00096
X3	6.24122
X4	4.00864
X6	5.98123
X7	1.03655

Możemy zauważyć, że wszystkie zmienne są istotnie różne od zera.

0.1.2 podpunkt b

Testujemy, czy którakolwiek ze zmiennych objaśniających w modelu **M** ma liniowy wpływ na zmienną objaśnianą. W tym celu przeprowadzamy test F.

```r
opis_modelu <- summary(model.aic)
wart_F_nowy <- opis_modelu$fstatistic
p_F_nowy <- pf(wart_F_nowy,
               opis_modelu$df[1],
               opis_modelu$df[2],
               lower.tail = FALSE)
p_wart <- p_F_nowy[1]
```

Wartość p-value wynosi $1.3434026 \times 10^{-291}$, jest ona niższa od jakiegokolwiek sensownego poziomu istotności dla testu. Zatem, odrzucamy hipotezę H_0. Przyjmujemy hipotezę $H_1 : \exists i \in 1, 2, 3, 4, 6, 7 \quad \beta_i \neq 0$. Oznacza to, że co najmniej jedna ze zmiennych objaśniających ma liniowy wpływ na Y.

0.1.3 podpunkt c

Dla każdej zmiennej objaśniającej z modelu **M** testujemy, czy ma ona liniowy wpływ na zmienną objaśnianą przy uwzględnieniu pozostałych zmiennych objaśniających w modelu.

```r
summary(model.aic)$coefficients[,4]
```

```
##   (Intercept)            X1            X2            X3            X4
##  3.506941e-01  4.320272e-78 5.861932e-243 3.734065e-158 3.092722e-165
##            X6            X7
## 5.027187e-268  2.146832e-94
```

Korzystając z testu t-Studenta na poziomie istotności $\alpha = 0.05$, wszystkie hipotezy zerowe, tzn. $H_0 : \beta_i = 0 \; \forall i \in \{1, 2, 3, 4, 6, 7\}$, zostają odrzucone (nie uwzględniamy zmiennej `Intercept`).

Zatem każda ze zmiennych objaśniających ma liniowy wpływ na zmienną objaśnianą.

0.1.4 podpunkt d

Wyznaczamy realizacje przedziałów ufności na poziomie 0,95 dla współczynników regresji odpowiadających zmiennym z modelu **M**. Do wyznaczenia realizacji wykorzystujemy funkcję `confint()`.

Tabela 2: Realizacje 95% przedziałów ufności dla współczynników regresji odpowiadających zmiennym z modelu M

	2.5 %	97.5 %
(Intercept)	-0.819	0.292
X1	1.903	2.142
X2	3.976	4.026
X3	6.120	6.363
X4	3.938	4.080
X6	5.954	6.009
X7	0.988	1.085

Możemy zauważyć, że żadna z realizacji dla nietrywialnych zmiennych objaśniających, nie zawiera zera. Potwierdza to słuszność wniosków z podpunktu 1c. W przypadku zmiennych $X_1, X_2, X_3, X_4, X_6, X_7$ obserwujemy dość wąskie realizacje przedziałów.

0.1.5 podpunkt e

Wyznaczamy skorygowany współczynnik determinacji R^2_{adj} modelu **M**.

```r
adj_R_kw <- summary(model.aic)$adj.r.squared
```

Skorygowany współczynnik determinacji wynosi 0.9994672, jest to wartość bardzo bliska 1. Sugeruje to bardzo dobre wyjaśnienie zmienności danych i dopasowanie modelu do obserwacji.

0.2 Zdanie 2

Analizujemy zachowanie reszt w modelu **M** w celu weryfikacji poprawności założeń modelu regresji liniowej.

0.2.1 Podpunkt a

Wyznaczamy rezydua modelu M.

```r
rezydua <- residuals(model.aic)
```

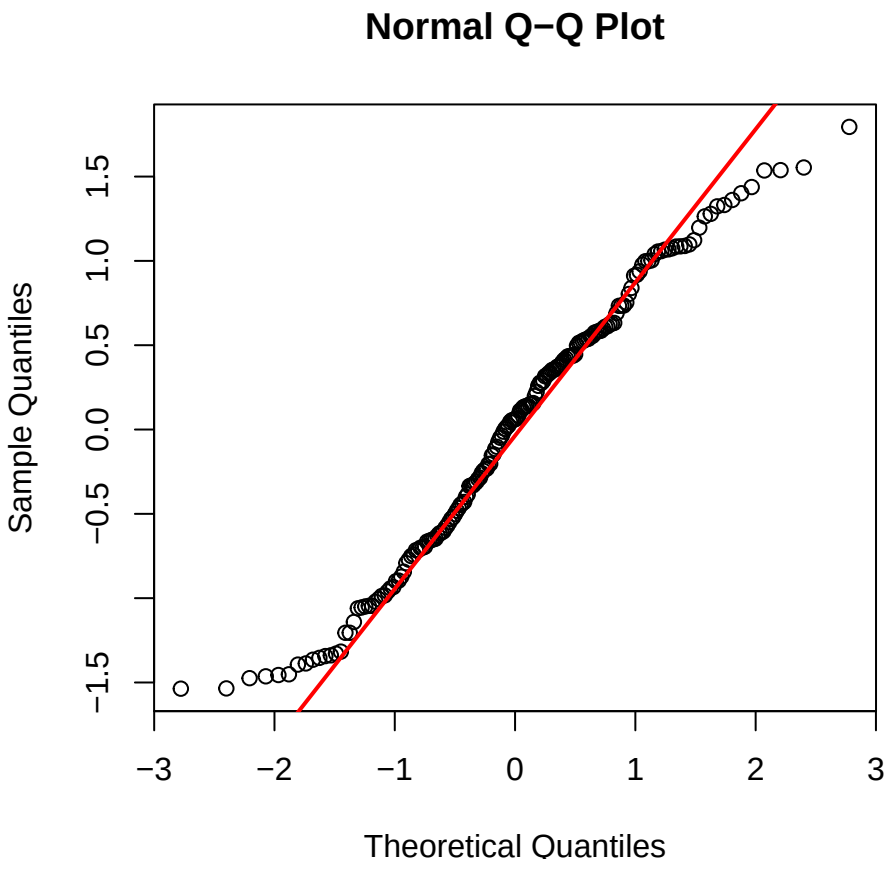

Możemy zauważyć, że kwantyle znacznie odstają na krańcach wykresu. Nie są one ułożone wzdłuż linii prostej. Zatem odrzucamy założenie o normalności reszt w modelu.

Testowanie hipotez w tym wypadku i wyznaczanie realizacji przedziałów ufności nie jest do końca poprawne, ponieważ reszty nie są z rozkładu normalnego.

0.2.2 Podpunkt b

Wykonujemy wykresy reszt względem każdej ze zmiennych objaśniających w modelu **M**.

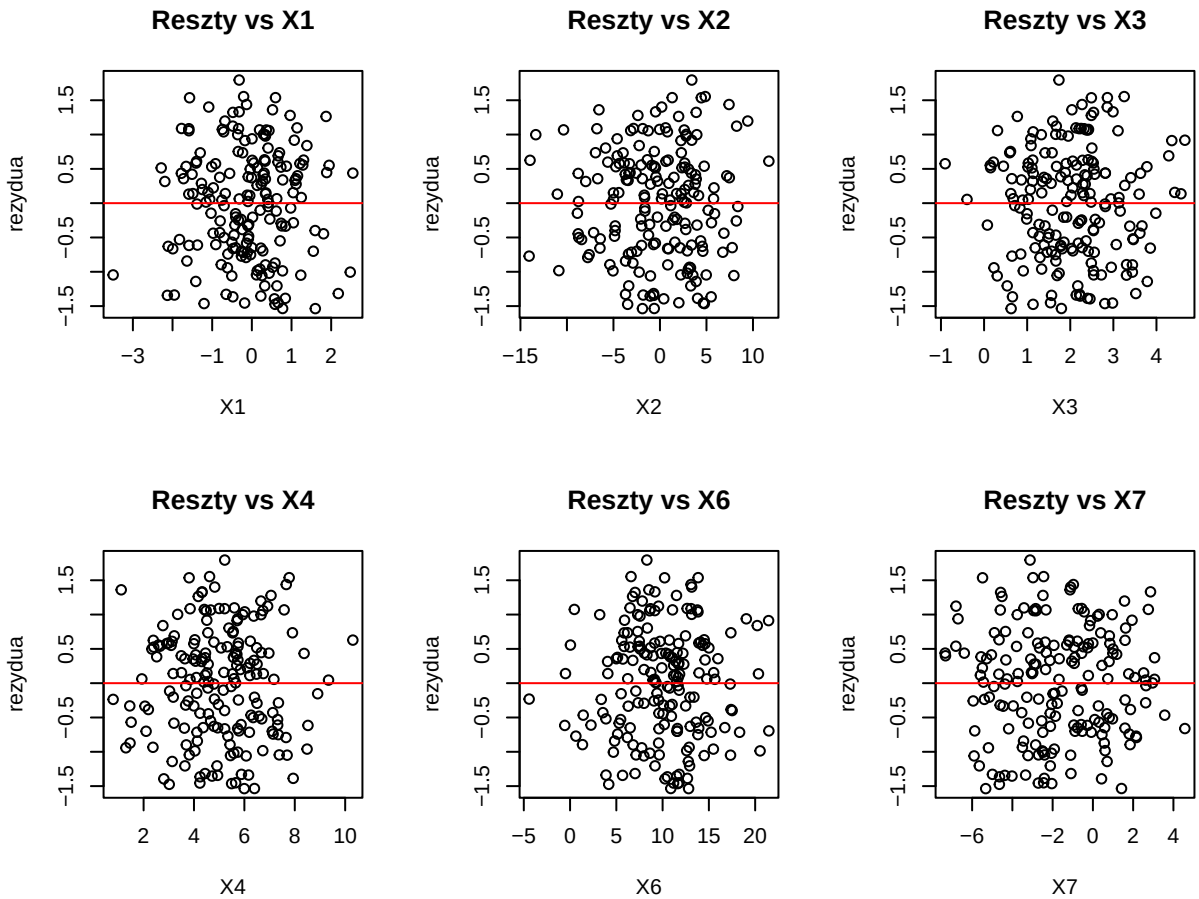

Żaden z wykresów nie wskazuje na osobliwe zachowanie zmiennych. Reszty są losowo rozproszone wokół osi y.

0.2.3 Podpunkt c

Wykonujemy wykresy reszt względem wartości przewidywanych przez model **M**.

```
y_predykcje <- model.aic$fitted.values
```

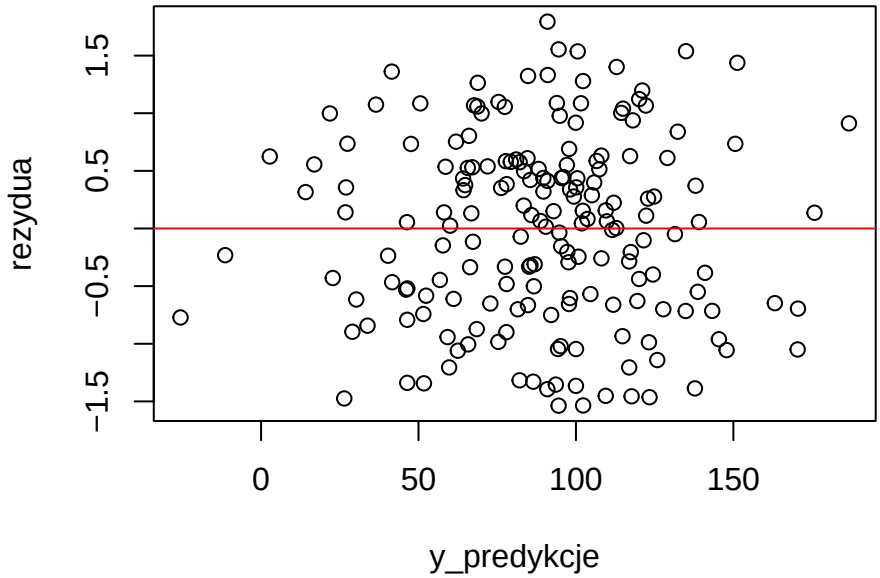

Chmura punktów jest losowo rozproszona, nie występują żadne wzorce czy trendy w danych. Dane są rozmieszczone wokół osi $y = 0$, co oznacza, że model wychwycił wszystkie zależności liniowe w danych.