

Zadanie laboratoryjne 8

Dawid Skowroński

2026-05-06

1 Zadanie 1

Dla podanych parametrów generujemy 10 obserwacji postaci

$$y_i = \frac{\beta_1 x_i}{\beta_2 + x_i} + \beta_3 + \varepsilon_i, \quad i = 1, \dots, n$$

2 Zadanie 2

Funkcja $g(\mathbf{x}, \boldsymbol{\beta})$ ma postać

$$g(x_i, \beta_1, \beta_2, \beta_3) = \frac{\beta_1 x_i}{\beta_2 + x_i} + \beta_3, \quad i = 1, \dots, n$$

Gradient $\nabla g(\mathbf{x}, \boldsymbol{\beta})$ ma postać

$$\nabla g(\mathbf{x}, \boldsymbol{\beta}) = \frac{\partial g(\mathbf{x}, \boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = \left[\frac{x_i}{\beta_2 + x_i}, -\frac{\beta_1 x_i}{(\beta_2 + x_i)^2}, 1 \right]$$

Definiujemy funkcję g i jej gradient.

```
fun_g <- function(x,beta){  
  return((beta[1] * x) / (beta[2] + x) + beta[3])  
}  
  
grad_g <- function(x, beta){  
  return(c(x/(beta[2]+x), - (beta[1] *x)/(beta[2]+x)^2,1))  
}
```

3 Zadanie 3

Wyznaczamy estymatory $(\widehat{\beta}_1, \widehat{\beta}_2, \widehat{\beta}_3, \widehat{\sigma}^2)$ parametrów $(\beta_1, \beta_2, \beta_3, \sigma^2)$.

Jako punkt startowy przyjmujemy $(\beta_1^{(0)}, \beta_2^{(0)}, \beta_3^{(0)}) = (8, 2, 1)$

Kryterium stopu:

$$\|\widehat{\beta}^{(n)} - \widehat{\beta}^{(n-1)}\| \leq 0.0001 \quad \text{lub} \quad n = 100.$$

Definiujemy macierz G .

```

mac_G <- function(wek_x, beta){
  n <- length(wek_x)
  p <- length(beta)
  mac <- matrix(nrow = n, ncol = p)
  for (i in 1:n){
    mac[i, ] <- grad_g(wek_x[i], beta = beta)
  }
  return(mac)
}

```

Implementujemy algorytm Gaussa-Newtona.

```

G.N <- function(x,y, beta_0 = c(8,2,1), eps=0.0001 , M=100){

  p <- length(beta_0)

  stare_beta <- beta_0
  for (i in 1:M){

    y_prog <- fun_g(x, stare_beta)
    G <- mac_G(x, beta = stare_beta)

    krok <- ginv(t(G) %*% G) %*%
      t(G)%*%(y-y_prog)

    nowe_beta <- stare_beta + krok

    # Warunek stopu
    if (sqrt(sum((nowe_beta-stare_beta)^2))<eps){
      break
    }
    stare_beta <- nowe_beta
  }

  # Oszacowanie wariancji
  y_koniec <- fun_g(x, nowe_beta)
  SSR <- sum((y - y_koniec)^2)
  sig_kw <- SSR / (n - p)

  # Oszacowanie macierzy kowariancji
  mac_cov <- sig_kw * ginv(t(G)%*%G)

  return(list(beta_est = nowe_beta, sigma2_est = sig_kw, iteracje = i, macierz_cov = mac_cov))
}

```

4 Zadanie 4

Dla kroków $s = 0, 1, 2, \dots$ oraz $s=\text{ostatni}$ wyznaczamy wartości estymatorów $\hat{\beta}^{(s)}, (\hat{\sigma}^2)^{(s)}$ oraz wartość funkcji logarytmu wiarygodności $l(s) = l(\hat{\beta}^{(s)}, (\hat{\sigma}^2)^{(s)})$.

```

G.N_tab <- function(x,
                    y,
                    beta_0 = c(8, 2, 1),

```

```

        eps = 0.0001 ,
        M = 100) {
n <- length(x)
p <- length(beta_0)

historia <- data.frame()

stare_beta <- beta_0
for (i in 1:M) {
  y_prog <- fun_g(x, stare_beta)
  G <- mac_G(x, beta = stare_beta)

  krok <- ginv(t(G) %*% G) %*%
    t(G) %*% (y - y_prog)

  SSR <- sum((y - y_prog) ^ 2)
  L_log <- -n / 2 * log(2 * pi) - n / 2 * log(SSR / (n - p)) - (n - p) /
    2

  historia <- rbind(
    historia,
    data.frame(
      krok = i - 1,
      beta1 = stare_beta[1],
      beta2 = stare_beta[2],
      beta3 = stare_beta[3],
      sigma_kw = SSR / (n - p),
      L = L_log
    )
  )

  nowe_beta <- stare_beta + krok

  # Warunek stopu
  if (sqrt(sum((nowe_beta - stare_beta) ^ 2)) < eps) {
    break
  }
  stare_beta <- nowe_beta
}

# Oszacowanie wariancji
y_koniec <- fun_g(x, nowe_beta)
SSR <- sum((y - y_koniec) ^ 2)
sig_kw <- SSR / (n - p)

L_log <- -n / 2 * log(2 * pi) - n / 2 * log(SSR / (n - p)) - (n - p) /
  2

historia <- rbind(
  historia,
  data.frame(

```

```

        krok = i,
        beta1 = nowe_beta[1],
        beta2 = nowe_beta[2],
        beta3 = nowe_beta[3],
        sigma_kw = SSR / (n - p),
        L = L_log
    )
)

return(list(
  beta_est = nowe_beta,
  sigma2_est = sig_kw,
  iteracje = i,
  historia = historia
))
}

```

5 Zadanie 5

Porównujemy estymator $\hat{\beta}$ parametru β z rzeczywistą wartością β .

##	krok	beta1	beta2	beta3
## 1	0	8	2	1
## 2	1	9.05772473184738	3.1290551061141	2.67905619402057
## 3	2	9.50755398814733	3.30107719134622	2.49725479782213
## 7	6	9.50411731626483	3.28632102932519	2.49138116147539
## 5 rzeczywiste		10	3	2

##	sigma_kw	L
## 1	2.25533561146646	-16.7558792910426
## 2	0.0625198647939062	1.17196934813661
## 3	0.0449182524894541	2.82516993093686
## 7	0.0449091077048311	2.82618797094548
## 5	0.25	-3.23763860459806


Możemy zauważyć, że zarówno oszacowania parametru β oraz wariancji zbliża się do rzeczywistych wartości tych parametrów. Po końcowej iteracji wartości są dość dobrze zbliżone do rzeczywistych wartości

Wartość logarytmu funkcji wiarygodności rośnie przy kolejnych iteracjach.

6 Zadanie 6

Na wykresie przedstawiamy wykresy rozrzutu punktów (x_i, y_i) oraz $(x_i, \hat{y}_i)$, gdzie $\hat{y}_i = g(x_i, \hat{\beta})$.

```
y_pred <- fun_g(x, G_N_rozw$beta_est)
```



Czarne punkty przedstawiają rzeczywiste wartości y_i , natomiast czerwone punkty przedstawiają wartości prognozowane.

Możemy zauważyć, że model jest dobrze dopasowany do rzeczywistych wartości.

7 Zadanie 7

Wyznaczamy oszacowanie macierzy kowariancji estymatora $\hat{\beta}$.

```
##           [,1]      [,2]      [,3]
## [1,] 0.8834588 0.9564455 0.2417275
## [2,] 0.9564455 1.3490988 0.4630002
## [3,] 0.2417275 0.4630002 0.1998337
```

Najmniejszą wartość na przekątnej otrzymujemy dla ostatniego elementu przekątnej.

8 Zadanie 8

Za pomocą algorytmu Gaussa-Newtona wyznaczamy estymatory $(\hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3, \hat{\sigma}^2)$ parametrów $(\beta_1, \beta_2, \beta_3, \sigma^2)$ dla punktów:

- a) $(\beta_1^{(0)}, \beta_2^{(0)}, \beta_3^{(0)}) = (9.7, 2.9, 2)$,
- b) $(\beta_1^{(0)}, \beta_2^{(0)}, \beta_3^{(0)}) = (1, 1, 1)$.

Warunek stopu ustalamy taki sam jak w zadaniu 3.

9 Zadanie 9

Porównujemy wyniki otrzymane w zadaniu 8. i 3.

- a) $(\beta_1^{(0)}, \beta_2^{(0)}, \beta_3^{(0)}) = (9.7, 2.9, 2)$,

```
##  krok    beta1    beta2    beta3  sigma_kw      L
##  1      0  9.700000  2.900000  2.000000  0.07996628 -0.05863436
##  2      1  9.488253  3.269595  2.510475  0.04567723  2.74139169
##  3      2  9.505100  3.287756  2.491903  0.04490912  2.82618674
##  4      3  9.504025  3.286192  2.491337  0.04490911  2.82618796
##  5      4  9.504125  3.286331  2.491385  0.04490911  2.82618797
##  6      5  9.504116  3.286319  2.491380  0.04490911  2.82618797
```

Dla punktu $(9.7, 2.9, 2)$ otrzymujemy wyniki bardzo zbliżone do oszacowań, gdy algorytm startował z punktu $(8, 2, 1)$

- b) $(\beta_1^{(0)}, \beta_2^{(0)}, \beta_3^{(0)}) = (1, 1, 1)$.

```
##  krok    beta1    beta2    beta3  sigma_kw      L
##  1      0  1.000000  1.00000  1.000000  35.4261783 -30.526641
##  2      1  6.853363  12.50565  4.078620  3.3056654 -18.667574
##  3      2 -8.195866 -57.78390  2.642181  18.9437739 -27.396762
##  4      3 -48.564859 -51.46841  3.985024  0.3726086 -7.753251
##  5      4 -524.472084 -507.80799  2.945794  0.8999493 -12.162301
##  6      5 -502.247629 -531.01262  3.887731  0.1965233 -4.554513
##  7      6 -501.143649 -532.06771  3.887603  0.1962990 -4.548805
##  8      7 -501.142203 -532.06908  3.887596  0.1962990 -4.548805
##  9      8 -501.142204 -532.06908  3.887596  0.1962990 -4.548805
```

Dla punktu $(1, 1, 1)$ algorytm przeprowadził najwięcej iteracji, jednak otrzymane oszacowania są bardzo odległe od wartości rzeczywistych wartości parametrów. Otrzymaliśmy jednak najlepsze oszacowanie parametru σ^2 . Obserwujemy także mniejszą wartość logarytmu funkcji wiarygodności niż w przypadku pozostałych punktów startowych.