

# Sprawozdanie - regresja logistyczna

Dawid Skowroński

2026-05-13

## 1 Generowanie zbioru danych do regresji logistycznej

Na podstawie odpowiednich wartości parametrów generujemy dane, rozmiar próby  $n=300$ , liczba zmiennych objaśniających  $p=20$ . Zmienna objaśniająca  $X_1$  jest stale równa 1.

Przyjmujemy, że tylko zmienne  $X_1, \dots, X_{10}$  mają niezerowe współczynniki  $\beta_1, \dots, \beta_{10}$ . Pozostałe zmienne mają odpowiednie współczynniki regresji równe 0.

Zmienne objaśniane będziemy generować z rozkładu standardowego normalnego, natomiast zmienna objaśniana  $Y$  jest zmienną binarną, która przyjmuje wartości 0 i 1 z prawdopodobieństwem odpowiednio  $1 - \pi(x_i)$  oraz  $\pi(x_i)$ .

```
n <- 300
p <- 20

X <- matrix(rnorm(n*p,2,5),ncol = p, nrow = n)
X[,1] <- rep(1,n)

beta <- c(rnorm(10,0,1/4),numeric(10))

pi <- 1/(1 + exp(-X %*% beta))

colnames(X) <- sapply(1:p, function(i){paste0("X",i)})

dane <- data.frame(X)
dane$Y <- rbinom(n,1,pi)
```

Otrzymane dane łączymy w ramkę danych i zapisujemy do pliku CSV.

```
colnames(X) <- sapply(1:p, function(i){paste0("X",i)})

dane <- data.frame(X)
dane$Y <- rbinom(n,1,pi)

# Zapisanie danych do pliku
write.csv(dane, "dane.csv", row.names = FALSE)
```

## 2 Konstrukcja modelu regresji logistycznej

### 2.1 Zadanie 1

Wczytujemy wcześniej wygenerowane dane i dokonujemy podziału na zbiór treningowy oraz testowy w proporcji 70:30.

```

dane <- read.csv(
  file = 'dane.csv',
  sep = ",",
  dec = ".",
  check.names = FALSE
)

ind.y0 <- which(dane$Y==0)
ind.y1 <- which(dane$Y==1)

# Dzielimy dane na zbiory zawierające y=1 i y=0
train.0 <- sample(ind.y0, size = floor(0.7*length(ind.y0)))
train.1 <- sample(ind.y1, size = floor(0.7*length(ind.y1)))

ind.train <- sort(c(train.0,train.1))
ind.test <- setdiff(seq_len(nrow(dane)), ind.train)

# Zbiór uczący
train <- dane[ind.train,]
# Zbiór testowy
test <- dane[ind.test,]

```

Wygenerowane dane zawierają obserwacje, dla których zmienna objaśniana  $Y$  przyjmuje wartość 1.

Wyznaczamy średnią w obu zbiorach, aby sprawdzić czy frakcja rekordów ze zmienną  $y=1$  jest zbliżona.

```
mean(train$Y)
```

```
## [1] 0.4545455
```

```
mean(test$Y)
```

```
## [1] 0.4615385
```

Na podstawie zbioru treningowego tworzymy model regresji logistycznej.

```
model.pelny <- glm(Y~., data = train[-1], family = binomial)
```

```
model.0 <- glm(Y~1, data = train[-1], family = binomial)
```

Za pomocą testu ilorazu wiarygodności weryfikujemy hipotezę zerową  $H_0 : \beta_2 = \dots = \beta_p = 0$ , która stwierdza, że żadna ze zmiennych objaśniających  $X_2, \dots, X_p$  nie wpływa na zmienną objaśnianą  $Y$ .

```
test.anova <- anova(model.0, model.pelny, test = 'LRT')
pval <- test.anova$`Pr(>Chi)`[2]
```

Otrzymujemy  $p$ -wartość równą  $1.3446218 \times 10^{-25}$ . Oznacza to, że na poziomie istotności  $\alpha=0.05$  należy odrzucić hipotezę  $H_0$ , tzn. przynajmniej jedna ze zmiennych objaśnianych  $X_2, \dots, X_p$  wpływa na zmienną objaśnianą  $Y$ .

Dla każdego z parametrów  $\beta_i, i = 2, \dots, p$

a) wyznaczamy estymatory parametrów  $\beta_i$  oraz ich błędy standardowe,

```
info <- round(summary(model.pelny)$coefficients, 6)
info
```

```
##              Estimate Std. Error   z value Pr(>|z|)
## (Intercept) -0.405970   0.516868 -0.785442 0.432195
```

```
## X2          0.307523    0.066280    4.639745    0.000003
## X3         -0.269407    0.061325   -4.393132    0.000011
## X4          0.004541    0.049763    0.091251    0.927293
## X5          0.144464    0.052549    2.749140    0.005975
## X6         -0.222081    0.058119   -3.821135    0.000133
## X7          0.039269    0.045516    0.862745    0.388278
## X8          0.428191    0.077676    5.512543    0.000000
## X9         -0.089267    0.052718   -1.693278    0.090403
## X10         -0.332931    0.067461   -4.935140    0.000001
## X11          0.030157    0.051458    0.586050    0.557842
## X12         -0.045666    0.047718   -0.956991    0.338572
## X13         -0.112635    0.061328   -1.836607    0.066268
## X14          0.036151    0.056108    0.644320    0.519368
## X15         -0.107881    0.058251   -1.852006    0.064025
## X16          0.096506    0.059099    1.632961    0.102477
## X17          0.183232    0.059145    3.098008    0.001948
## X18          0.065334    0.051949    1.257652    0.208518
## X19          0.003461    0.053816    0.064321    0.948715
## X20         -0.074733    0.055444   -1.347895    0.177692
```

b) tworzymy realizacje przedziałów ufności na poziomie  $1 - \alpha$ ,

```
przedzialy <- confint(model.pelny)
przedzialy
```

```
##              2.5 %      97.5 %
## (Intercept) -1.44907539  0.594209285
## X2           0.18808826  0.449956661
## X3          -0.40057491 -0.158025037
## X4          -0.09474239  0.102210026
## X5           0.04693442  0.254619400
## X6          -0.34507791 -0.115094582
## X7          -0.05024767  0.129638375
## X8           0.28909468  0.595858885
## X9          -0.19731572  0.011118052
## X10         -0.47938735 -0.212307874
## X11         -0.06948406  0.133796153
## X12         -0.14259713  0.046088202
## X13         -0.23727184  0.005201151
## X14         -0.07260896  0.149252484
## X15         -0.22789906  0.003041305
## X16         -0.01701829  0.216822579
## X17          0.07427372  0.307857901
## X18         -0.03645918  0.169091949
## X19         -0.10310653  0.110283028
## X20         -0.18645271  0.033333342
```

c) weryfikujemy hipotezę  $H_0 : \beta_i = 0$  przeciwko  $H_1 : \beta_i \neq 0$

Jeśli wartość 0 nie znajduje się wewnątrz realizacji przedziału ufności, nie mamy podstaw do odrzucenia hipotezy  $H_0$ .

Zatem, istotne zmienne to:  $X_2, X_3, X_5, X_6, X_8, X_{10}, X_{17}$ .

Porównujemy wektor parametrów  $\beta$  z jego estymatorem  $\hat{\beta}$ .

```
##              beta
## (Intercept) -0.17480703 -0.405970029
```

```
## X2      0.24911288  0.307522815
## X3     -0.17318634 -0.269407052
## X4     -0.02587076  0.004540912
## X5      0.15096652  0.144464490
## X6     -0.15201125 -0.222080710
## X7      0.02121653  0.039269128
## X8      0.39449755  0.428191492
## X9     -0.11591344 -0.089266673
## X10     -0.28963175 -0.332931112
## X11      0.00000000  0.030157067
## X12      0.00000000 -0.045666047
## X13      0.00000000 -0.112635083
## X14      0.00000000  0.036151228
## X15      0.00000000 -0.107881075
## X16      0.00000000  0.096505777
## X17      0.00000000  0.183232357
## X18      0.00000000  0.065333642
## X19      0.00000000  0.003461480
## X20      0.00000000 -0.074732535
```

Możemy zauważyć, że dla niektórych zmiennych (np. dla  $X_4$ ) estymator błędnie zidentyfikował znaki elementów wektora  $\beta$ . Większość wartości estymatora jest zbliżona do rzeczywistych niezerowych wartości wektora  $\beta$ . Natomiast, zerowe elementy wektora  $\beta$  zostały błędnie zidentyfikowane.

## 2.2 Zadanie 2

Wyznaczamy iloraz szans zmiennej  $X_i = e^{\beta_i}$

```
szansa <- exp(coef(model.pelny))
szansa
```

```
## (Intercept)      X2      X3      X4      X5      X6
##  0.6663301  1.3600518  0.7638323  1.0045512  1.1554207  0.8008507
##      X7      X8      X9      X10      X11      X12
##  1.0400504  1.5344799  0.9146016  0.7168196  1.0306164  0.9553610
##      X13      X14      X15      X16      X17      X18
##  0.8934766  1.0368126  0.8977344  1.1013159  1.2010935  1.0675151
##      X19      X20
##  1.0034675  0.9279917
```

Dla zmiennej  $X_2$  oznacza to, że jeśli zwiększymy wartość zmiennej  $X_2$  o jeden, to szansa na to, że zmienna  $Y$  przyjmie wartość równą 1 wzrasta o około 36%.

Dla zmiennej  $X_3$  oznacza to, że jeśli zwiększymy wartość zmiennej  $X_3$  o jeden, to szansa na to, że zmienna  $Y$  przyjmie wartość równą 1 maleje o około 24%.

## 2.3 Zadanie 3

Wyznaczamy oszacowane prawdopodobieństwa wartości  $Y$  dla każdej z obserwacji zbioru testowego. Tworzymy także tabelę klasyfikacji oraz miary zdolności predykcyjnej modelu.

```
predict.test <- predict(model.pelny, newdata = test, type = 'response')

#Informacja o macierzy pomyłek
info.cm <- function(punkt){
  pred.class <- ifelse(predict.test>punkt,1,0)
```

```

# Macierz pomyłek
cm <- table(pred=pred.class, real = test$Y)

sensit <- cm[2,2]/sum(cm[,2])
specif <- cm[1,1]/sum(cm[,1])
fpr <- cm[2,1]/sum(cm[,1])
fnr <- cm[1,2]/sum(cm[,2])

acc <- sum(diag(cm))/sum(cm)

return(list(cm=cm,sensit=sensit,specif=specif,fpr=fpr,fnr=fnr, acc=acc))
}

M.1 <- info.cm(0.5)
M.2 <- info.cm(0.7)

M.1$cm

##      real
## pred  0  1
##      0 42 13
##      1  7 29

M.2$cm

##      real
## pred  0  1
##      0 45 16
##      1  4 26

zestawienie <- rbind(c(0.5,0.7),cbind(M.1[-1],M.2[-1]))
zestawienie

##      [,1]      [,2]
##      0.5      0.7
## sensit 0.6904762 0.6190476
## specif 0.8571429 0.9183673
## fpr    0.1428571 0.08163265
## fnr    0.3095238 0.3809524
## acc    0.7802198 0.7802198

```

Analizując zestawienie miar, możemy zauważyć że dokładność jest równa dla obu modeli. Czulość jest większa dla odcięcia  $\pi_0=0.5$ , natomiast dla odcięcia  $\pi_0=0.7$  większa jest specyficzność. Zatem, stwierdzamy, że model z odcięciem  $\pi_0=0.5$  jest lepszy, ponieważ ma większą wartość czulości oraz mniejszą wartość FNR.

## 2.4 Zadanie 4

Wykorzystujemy zbiór testowy do narysowania krzywej ROC. Wyznaczyć pole pod krzywą ROC (AUC).

```

roc.obj <- roc(test$Y, predict.test)
auc <- auc(roc.obj)

```

Wartość AUC wynosi 0.8979592, jest to wynik bliski 1. Oznacza to bardzo dobre dopasowanie modelu do danych testowych.

